

Аналитический отчет: Классическое машинное обучение

Цель работы:

Разработка и сравнение различных моделей ML для:

- Регрессия:
 - IC50
 - CC50
 - SI
- Классификация:
 - превышает ли значение IC50 медианное значение выборки
 - превышает ли значение CC50 медианное значение выборки
 - превышает ли значение SI медианное значение выборки
 - превышает ли значение SI значение 8

Этапы предобработки:

- Удаление столбцов с нулевым стандартным отклонением
- Удаление технического столбца (unnamed: 0)
- Замена null значений на медианные значения по этому столбцу
- Удаление строк, которые являются выбросами. То есть выше 99 перцентиля
- PCA для сокращения размерности, но позже была удалена, т.к. данные нелинейно зависимы
- Масштабирование признаков с помощью StandardScaler
- Логарифмирование целевых признаков для сглаживания выбросов
- Отбор 50 наиболее значимых признаков по отношению к каждой целевой переменной с помощью библиотеки `sklearn.feature_selection`
- Для каждой модели были подобраны лучшие гиперпараметры с помощью GridSearch

Задачи регрессии:

Были использованы 5 моделей для поиска регрессии, такие как:

- LinearRegression
- Ridge
- Lasso
- RandomForest
- XGBoost

XGBoost превосходит во всех случаях со всеми целевыми переменными другие модели и хорошо объясняет дисперсию.

R^2 XGBoost для разных целевых переменных:

- CC50 – 50%
- IC50 – 98%
- SI – 98%

Задачи классификации:

Были использованы 4 модели для классификации данных, такие как:

- Logistic Regression
- RandomForest
- XGBoost
- KNN

В данном случае XGBoost также показывает лучшие результаты.

Заключение:

1. Использовать XGBoost как основную модель в задачах регрессии и классификации
2. Всегда логарфмировать данные по целевым переменным перед обучением, чтобы сгладить шумы
3. В дальнейшем можно добавить более тщательный анализ важности признаков
4. Также можно добавить ансамбль моделей в задачах классификация. То есть объединить XGBoost и Logistic Regression